Anteproyecto

WikiLLM: compilación incremental de conocimiento para optimizar el contexto de modelos de lenguaje y personas

Juan Diego Ramírez Juan David Cruz García
juan.ramirezzuluaga@u.icesi.edu.co, juan.cruz6@u.icesi.edu.co

Resumen — Los sistemas de Recuperación Aumentada por Generación (RAG) responden cada consulta recuperando fragmentos y sintetizándolos de nuevo, sin conservar lo aprendido. En el patrón WikiLLM, en cambio, un agente compila las fuentes, una a una, en páginas markdown enlazadas que crecen y se corrigen con cada ingesta. Este anteproyecto plantea estudiar el WikiLLM como herramienta para construir una base de conocimiento incremental que reduzca el contexto que un modelo y una persona necesitan leer para responder correctamente. El estudio usa literatura abierta de inteligencia artificial publicada en arXiv después del corte de entrenamiento del modelo. Tras cada ingesta se guarda una copia del wiki y se mide, frente a una línea base RAG sobre el mismo corpus, la calidad de las respuestas, la cantidad de contexto consumido, el esfuerzo de lectura humana y el costo. Se espera aportar un protocolo de evaluación abierto y un primer conjunto de mediciones sobre cuándo conviene compilar el conocimiento en lugar de recuperarlo.

Palabras clave — Base de conocimiento incremental, ingeniería de contexto, modelos de lenguaje, recuperación aumentada por generación, WikiLLM.

I. Planteamiento del problema

Buscar información consume tiempo de trabajo: en un estudio con 716 empleados públicos, el 22,3 % dedicaba cerca de media jornada semanal a buscar la información que necesitaba (Nakash y Bouhnik, 2024). Los asistentes basados en RAG (Lewis et al., 2020) se adoptan para reducir ese costo: ante cada pregunta recuperan fragmentos por similitud semántica y el modelo redacta una respuesta a partir de ellos.

Este diseño tiene tres límites. Primero, la síntesis se repite completa en cada consulta y no se conserva (Karpathy, 2026). Segundo, el modelo recibe fragmentos sueltos, sin fecha ni señales sobre la calidad de su fuente, y debe reconciliar en el momento datos obsoletos o contradictorios. Tercero, la persona que verifica la respuesta solo ve esos mismos fragmentos. En los tres casos el recurso escaso es el *contexto*: los tokens que el modelo procesa en cada llamada, con su costo y su ruido, y el tiempo de lectura de la persona. Un contexto más grande no garantiza mejores respuestas; importa entregar la información pertinente en el menor texto posible.

El patrón WikiLLM (Karpathy, 2026) mueve la síntesis desde la consulta hacia la ingesta: un agente lee cada fuente nueva, actualiza las páginas afectadas de un wiki en markdown y registra las contradicciones. Las consultas se responden sobre páginas ya redactadas, enlazadas y fechadas, que también puede leer una persona. La Tabla I resume la diferencia.

El estudio usa literatura abierta de inteligencia artificial en arXiv, un caso exigente del problema: en febrero de 2026 llegaron más de 20.500 preprints de computación sin revisión por pares (arXiv, 2026), y el texto generado por modelos es casi seis veces más frecuente en los artículos que no son revisiones (Elazar y Antoniak, 2026). Al ser público, el corpus permite replicar el experimento.

Anteproyecto de la Maestría en Inteligencia Artificial Aplicada, Universidad Icesi, presentado para revisión del tutor. Repositorio: https://github.com/1KVueltasAlCampo/llm-knowledge-management-wiki-agent.

TABLA I
COMPARACIÓN ENTRE RAG Y EL PATRÓN WIKILLM

	RAG (línea base)	**WikiLLM (propuesta)**
Momento de la síntesis	En cada consulta	Una vez, al ingerir cada fuente
Qué se conserva	Fragmentos y vectores	Páginas redactadas y enlazadas
Contexto para el modelo	Fragmentos crudos por similitud	Páginas consolidadas, con fuente
Contexto para la persona	Fragmentos sueltos	Wiki navegable y versionado
Manejo de contradicciones	Implícito, al responder	Explícito, marcado y fechado
Falla característica	Recuperar un fragmento erróneo	Conservar un error de síntesis

II. ANTECEDENTES Y VACÍO DE INVESTIGACIÓN

La revisión del estado del arte identificó veinte trabajos de 2026 sobre el patrón, todos preprints, cuyos resultados frente a RAG no coinciden. Wright (2026) encuentra un empate en hechos puntuales y una ventaja del wiki en preguntas que cruzan unidades de un curso. En cambio, Zhang (2026) no observa ninguna variante del wiki que supere a RAG, y Huerta (2026a) reporta que compilar sin control pierde información en el 53–60 % de los casos, aunque una o dos rondas de refinamiento recuperan cerca del 80 % de la calidad perdida.

El argumento económico, el más ligado al contexto, también está en disputa. Wen y Ku (2026) estiman un 84,6 % menos de tokens acumulados que RAG, mientras que Cochran (2026a) mide que el wiki consume unas 21 veces más tokens por consulta. Cochran (2026b) muestra que la diferencia depende de cómo se accede al wiki: con acceso progresivo a las páginas, el costo baja entre un tercio y más de la mitad sin pérdida de calidad. Por último, la organización del wiki tiende a deteriorarse a medida que crece (Zhou et al., 2026).

Las comparaciones existentes evalúan un wiki ya construido, con muestras de 10 a 59 preguntas, y reportan el costo como un valor aislado. Ningún trabajo mide, tras cada ingesta, cuánto contexto necesitan un modelo y una persona para responder correctamente, ni si esa cantidad mejora o empeora a medida que el wiki crece y recibe fuentes de calidad desigual.

III. PREGUNTA, HIPÓTESIS Y OBJETIVOS

Pregunta de investigación. *¿En qué medida un WikiLLM mantenido de forma incremental reduce el contexto que un modelo de lenguaje y una persona necesitan para responder correctamente, y cómo evoluciona esa ventaja frente a un sistema RAG a medida que se ingieren nuevas fuentes?*

H1. A partir de cierto número de fuentes ingeridas, el WikiLLM obtiene una exactitud igual o mayor que RAG con menos tokens de contexto por respuesta correcta, y una persona encuentra la respuesta en menos tiempo.

H2. (Riesgo.) Compilar puede convertir afirmaciones débiles en prosa segura y conservar errores durante varias ingestas, lo que reduce o anula esa ventaja; si ocurre, se reportará.

Objetivo general. Evaluar el patrón WikiLLM como herramienta para construir una base de conocimiento incremental que optimice el contexto disponible para modelos de lenguaje y personas, en comparación con RAG.

Objetivos específicos: (1) construir un corpus versionado de 30 a 50 preprints y preguntas de control con respuesta verificable; (2) implementar un agente WikiLLM que conserve la fuente de cada afirmación y someta sus cambios a revisión humana; (3) implementar una línea base RAG reproducible sobre el mismo corpus; y (4) medir tras cada ingesta la calidad, el contexto consumido, el esfuerzo humano y el costo de ambos sistemas.

IV. Metodología

A. Corpus

Se selecciona una subárea de inteligencia artificial con tablas de clasificación activas y una ventana temporal posterior al corte de entrenamiento del modelo. Así, las afirmaciones son numéricas, fechadas y verificables, y el modelo no puede responder de memoria. Cada afirmación conserva su fuente y señales de respaldo: disponibilidad de código, estado de publicación y versión del preprint.

B. Sistema

El agente se implementa en Python con `litellm`, lo que permite cambiar de proveedor de modelo sin modificar el código y registrar los tokens de cada llamada. Ejecuta tres operaciones: *ingesta* (leer una fuente y actualizar las páginas afectadas), *consulta* (responder con citas a páginas del wiki) y *revisión* o *lint* (detectar contradicciones, datos obsoletos y páginas sin enlaces). El agente no escribe directamente: entrega sus cambios como *Pull Request* en Git y un revisor los aprueba en Obsidian, lo que deja registrado el costo de la supervisión humana.

C. Protocolo experimental

Las fuentes se ordenan por fecha y se ingieren de a una. Tras cada ingesta se guarda una copia versionada del wiki, y sobre cada copia se responde el mismo conjunto de sesenta preguntas de control. Los dos autores fijan por separado cada respuesta correcta y se reporta su acuerdo. RAG usa el mismo corpus, modelo y preguntas. Se varían la frecuencia de la revisión automática y el grado de intervención humana, y se introducen a propósito errores y fuentes de baja calidad.

D. Métricas

En la Tabla II, las dos primeras métricas responden a la pregunta; las demás controlan que la reducción de contexto no cueste calidad.

Tabla II
Métricas de evaluación

Métrica	**Qué mide**
Eficiencia de contexto	Respuestas correctas por cada mil tokens de contexto del modelo.
Esfuerzo humano	Palabras y minutos de lectura para hallar la respuesta (15 preguntas).
Cobertura	Proporción de preguntas de control respondidas correctamente.
Fundamentación	Proporción de afirmaciones rastreables hasta su fuente.
Contradicciones	Si el wiki se corrige cuando una fuente nueva supera un dato.
Persistencia del error	Ingestas que sobrevive un error introducido a propósito.
Costo	Tokens y tiempo por ingesta y por consulta frente a RAG.

Se usan respuestas fijadas por los autores y no solo un modelo como juez, cuyo acuerdo es bajo (Cochran, 2026a) y que se sesga con contenido posterior a su corte (Huerta, 2026b).

V. Resultados esperados y contribución

Se espera obtener una curva por métrica a lo largo de las ingestas para ambos sistemas y el punto de equilibrio: el número de consultas por fuente a partir del cual compilar resulta más barato que recuperar. Un resultado desfavorable al WikiLLM también es válido, porque delimita cuándo conviene cada arquitectura. La contribución es un protocolo de evaluación del mantenimiento incremental que incluye el contexto consumido por el modelo y por la persona, un primer conjunto de mediciones y una implementación abierta bajo licencia MIT.

VI. Plan de trabajo

La Tabla III cuenta las semanas desde la aprobación; las fechas se acordarán con el tutor.

Tabla III
Fases y entregables

Fase	Semanas	Entregable
F0 Delimitación	1	Subárea, ventana temporal y criterio de inclusión.
F1 Corpus	2–3	Corpus versionado con metadatos de calidad.
F2 Protocolo	4–5	Preguntas de control y script de evaluación.
F3 Agente WikiLLM	6–7	Ingesta, consulta y revisión con aprobación humana.
F4 Línea base	8–9	RAG reproducible y registro de costos.
F5 Experimento	10–11	Ingestas, variantes de revisión e inyección de errores.
F6 Cierre	12–13	Informe, guía de reproducción y sustentación.

Ante retrasos se recortan, en orden, las variantes de intervención humana, las de revisión y el número de fuentes; la línea base y la inyección de errores se mantienen.

VII. Alcance, riesgos y consideraciones éticas

El trabajo cubre un solo dominio y de 30 a 50 fuentes; su extensión a bases corporativas queda como trabajo futuro. Que los autores construyan las preguntas es un sesgo que se reduce, sin eliminarse, al responderlas por separado.

En seguridad, una fuente puede traer instrucciones para el agente; por eso las fuentes se tratan como datos y toda escritura pasa por revisión humana. En sesgo, se mide si el sistema presenta afirmaciones débiles como seguras. En privacidad, el corpus es público y el sistema admite un modelo local.

Referencias

arXiv. (2026). *Monthly submissions*. https://arxiv.org/stats/monthly_submissions

Cochran, T. O. (2026a). *Single-round vector RAG vs an LLM-compiled wiki: A preregistered comparison on a small multi-domain research corpus* (arXiv:2605.18490). arXiv. https://arxiv.org/abs/2605.18490

Cochran, T. O. (2026b). *Progressive disclosure for LLM-maintained wiki knowledge bases: A preregistered ablation* (arXiv:2607.04576). arXiv. https://arxiv.org/abs/2607.04576

Elazar, Y., y Antoniak, M. (2026). *LLM-generated or human-written? Comparing review and non-review papers on arXiv* (arXiv:2601.17036). arXiv. https://arxiv.org/abs/2601.17036

Huerta, J. M. (2026a). *WiCER: Wiki-memory compile, evaluate, refine. Iterative knowledge compilation for LLM wiki systems* (arXiv:2605.07068). arXiv. https://arxiv.org/abs/2605.07068

Huerta, J. M. (2026b). *Streaming knowledge compilation: Proactive materiality-scored pinning for time-evolving LLM wikis* (arXiv:2606.09877). arXiv. https://arxiv.org/abs/2606.09877

Karpathy, A. (2026, 4 de abril). *LLM wiki: A pattern for building personal knowledge bases using LLMs* [Gist]. GitHub. https://gist.github.com/karpathy/442a6bf555914893e9891c11519de94f

Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., et al. (2020). Retrieval-augmented generation for knowledge-intensive NLP tasks. En *Advances in Neural Information Processing Systems 33 (NeurIPS 2020)*. https://arxiv.org/abs/2005.11401

Nakash, M., y Bouhnik, D. (2024). How much time does the workforce spend searching for information in the "new normal"? En *iConference 2024 Proceedings*. https://www.ideals.illinois.edu/items/129980

Wen, S., y Ku, B. (2026). *Knowledge compounding: An empirical economic analysis of self-evolving knowledge wikis under the agentic ROI framework* (arXiv:2604.11243). arXiv. https://arxiv.org/abs/2604.11243

Wright, B. (2026). *Potential for enhanced learning in machine learning classes by using wiki LLM indexing* (arXiv:2609.25303). arXiv. https://arxiv.org/abs/2609.25303

Zhang, B. (2026). *Does the wiki grow smarter? A pilot evaluation of LLM-maintained knowledge bases in an exception-dense decision-support task* [Preprint]. SciErXiv. https://doi.org/10.20517/scierxiv202605.0291.v1

Zhou, S., Yu, S., Wei, H., Wu, J., Ouyang, S., Jiao, Y., et al. (2026). *Filesystem-based memory for LLM agents: Organization, evolution, and sustainability* (arXiv:2607.26637). arXiv. https://arxiv.org/abs/2607.26637