Estado del arte: bases de conocimiento mantenidas por modelos de lenguaje (*LLM Wiki*)

Juan Diego Ramírez – Juan David Cruz
juan.ramirezzuluaga@u.icesi.edu.co, juan.cruz6@u.icesi.edu.co

Resumen — El patrón *LLM Wiki*, enunciado por Karpathy en abril de 2026, propone que un agente compile las fuentes una sola vez en un wiki persistente de markdown enlazado, en lugar de recuperar y sintetizar en cada consulta como hace RAG. Esta revisión reúne 65 referencias: la fuente primaria, 20 trabajos que estudian el patrón de forma directa y 44 de las líneas que lo anteceden o lo rodean (generación de artículos tipo wiki, RAG estructurado, memoria de agentes, consistencia y evaluación). La evidencia directa es reciente, casi toda en preprint, y no converge: las comparaciones contra RAG arrojan resultados a favor, en contra y dependientes de la línea base. Quedan sin medir la evolución de la calidad factual del wiki ingesta tras ingesta, la supervivencia de errores, el efecto de la revisión automática y el de la intervención humana.

Palabras clave — LLM Wiki, compilación de conocimiento, RAG, memoria de agentes, mantenimiento incremental, procedencia.

I. Alcance y método de revisión

Búsqueda. Se consultaron el repositorio arXiv y buscadores web generales con los términos *LLM Wiki*, *LLM-maintained wiki*, *knowledge compilation*, *agent-native wiki*, *filesystem memory* y *Karpathy*, más búsquedas dirigidas sobre memoria de agentes, obsolescencia, contradicción y propagación de errores. El punto de partida fue un conjunto inicial de seis artículos identificados por los autores, ampliado a partir de esas búsquedas.

Inclusión. Se incluyen trabajos con (i) relación directa con el patrón o con uno de sus componentes y (ii) metadatos verificables. Los identificadores, autores y títulos de todos los preprints se comprobaron contra el registro de arXiv; las sedes de publicación se reportan solo cuando constan en ese registro o en el propio artículo. Se excluyeron blogs y documentación de producto, salvo el gist de Karpathy, que es la fuente primaria. Se excluyó *LLM-WikiRace* (arXiv:2602.16902) pese a la cercanía de su nombre: evalúa planificación sobre hipervínculos de Wikipedia y no trata bases de conocimiento mantenidas por un modelo.

Nivel de evidencia. Cada trabajo se clasifica como *R* (revisado por pares en sede reconocida), *J* (revista de creación reciente, indexación no verificada), *P* (preprint) o *G* (literatura gris). Los resultados numéricos de trabajos *P*, *J* y *G* son los que reportan sus autores y no han sido replicados.

II. El patrón LLM Wiki

Karpathy (2026) lo presenta como un «archivo de ideas», no como software ni como artículo. Define tres capas: fuentes crudas inmutables; un wiki de páginas markdown enlazadas que el modelo escribe y mantiene; y un esquema (`CLAUDE.md`, `AGENTS.md`) que fija convenciones y flujos. Define tres operaciones: *ingest* (integrar una fuente y actualizar las páginas afectadas), *query* (responder con citas desde el wiki) y *lint* (detectar contradicciones, afirmaciones obsoletas y páginas huérfanas). Un índice (`index.md`) y un registro cronológico (`log.md`) sustituyen al buscador vectorial a escala pequeña.

La diferencia con RAG (Lewis et al., 2020) es el momento de la síntesis: RAG la hace en cada consulta

Revisión con corte al 3 de octubre de 2026. Proyecto de la Maestría en Inteligencia Artificial Aplicada, Universidad Icesi.

sobre fragmentos crudos; el wiki la hace una vez, al ingerir, y la conserva. El costo se traslada de la consulta al mantenimiento, y el modo de falla, de recuperar el fragmento equivocado a perpetuar un error de síntesis. El gist no aporta evaluación alguna.

III. Literatura directa sobre LLM Wiki

La Tabla I resume los 20 trabajos posteriores al gist que estudian el patrón. Ninguno ha sido publicado en una sede de primer nivel; todos son de 2026.

Tabla I
Trabajos que estudian directamente el patrón LLM Wiki

Referencia	Niv.	Aporte	Resultado reportado
Comparaciones empíricas contra RAG			
Zhang (2026a)	P	Piloto en diagnóstico de aguas residuales; 10 manuales, 40 casos ingeridos por lotes, 3 políticas de ingesta.	Ninguna variante del wiki supera a RAG. Describe tres fallas del mantenedor: fragmentación, atomización y sobrefusión.
Cochran (2026b)	P	Comparación prerregistrada: RAG vectorial frente a wiki compilado; 24 artículos, 13 preguntas, dos jueces ciegos.	El wiki conecta mejor hallazgos entre fuentes, pero gasta $\sim$21 veces más tokens por consulta; no hay punto de equilibrio. Un RAG con descomposición elimina casi toda la ventaja.
Wright (2026)	P	RAG frente a wiki sobre el corpus de un curso; 59 preguntas.	Empate en hechos puntuales; en preguntas que cruzan unidades, wiki 9,93 frente a 8,14 y 100 % frente a 64 % de fundamentación.
Huerta (2026b)	P	Mide la «brecha de compilación» en 17 dominios de RepLiQA (6.800 preguntas) y propone un ciclo compilar–evaluar–refinar.	La compilación a ciegas falla en 53–60 % de los casos y queda por debajo de RAG; una o dos iteraciones de refinamiento recuperan el 80 % de la calidad perdida.
Wen y Ku (2026)	P	Modelo económico del «interés compuesto» del conocimiento; cuatro consultas secuenciales.	84,6 % menos tokens acumulados que RAG; el resto son proyecciones calibradas, no mediciones.
Construcción, navegación y refinamiento			
Ming et al. (2026b)	P	Wiki con enlaces bidireccionales navegado por herramientas, más un «libro de errores» para autocorrección.	Supera a HippoRAG 2, LightRAG y GraphRAG por 2,0–8,1 puntos F1 en HotpotQA, MuSiQue y 2WikiMultiHopQA.
Ming et al. (2026a)	P	Entrena en conjunto a quien construye y a quien navega el wiki, con la utilidad en consultas como señal.	+6,3 puntos sobre el sistema anterior en AuthTrace.
Dong et al. (2026)	P	Modelo fundacional sobre un grafo de wiki.	Mejoras en cinco benchmarks de memoria y multisalto.
Huang et al. (2026a)	P	Refinamiento del wiki por aprendizaje por refuerzo: diagnostica defectos a partir de las consultas y los repara.	Mejoras consistentes en tareas posteriores; afirma que los defectos se acumulan con el uso iterativo.

Referencia	Niv.	Aporte	Resultado reportado
Ran et al. (2026)	P	Compila en orden cronológico 56 artículos en wiki y grafo; cada ingesta es una transición de estado inspeccionable.	Crecimiento mayormente aditivo y baja rotación estructural. No mide exactitud de respuestas.
Mantenimiento, escala y costo			
Huerta (2026a)	P	Formaliza la compilación sobre un flujo de documentos con presupuesto fijo de tokens; cota de arrepentimiento.	El LLM como juez introduce un sesgo cuando el contenido es posterior al corte de entrenamiento; propone medir arrepentimiento y no puntaje absoluto.
Zhou et al. (2026)	P	Primer estudio sistemático de memoria como sistema de archivos markdown que el agente organiza.	La organización reduce a la mitad el costo de búsqueda, pero se erosiona al crecer salvo con el modelo más fuerte, y no produce mejores respuestas.
Cochran (2026a)	P	Ablación prerregistrada de la estructura de acceso sobre un wiki real de 709 páginas, con contenido idéntico.	Calidad no inferior; el costo baja entre un tercio y más de la mitad. Un agente capaz no carga el índice: infiere la página.
Procedencia, gobernanza y marcos conceptuales			
Zhang (2026c)	J	Capa de procedencia: grafo tipado afirmación–evidencia, detección de ediciones silenciosas y propagación de retractaciones.	100 % de cobertura al propagar retractaciones en un corpus de 112 documentos.
Miteski (2026)	P	Perfil de gobernanza contra el atrincheramiento de interpretaciones en wikis personales.	Propuesta de diseño; sin evaluación.
Roynard (2026)	P	Argumenta que falta una capa de conocimiento, distinta de la memoria, en las arquitecturas cognitivas.	Conceptual.
Moreira y Sweet (2026)	P	Plantilla de wiki para trabajo colaborativo; conserva los resultados negativos.	Tres casos de estudio; una auditoría retroactiva rebajó coberturas declaradas de 20/20 a 14 y 12.
Garralda-Barrio (2026)	P	Artículo de visión: el wiki como evidencia de una «arquitectura de conocimiento».	Conceptual.
Aplicaciones			
Zhang (2026b)	J	Wiki de guías clínicas como fuente de restricciones para aprendizaje por refuerzo.	Solo el 1,3 % de las restricciones extraídas es ejecutable.
Sun et al. (2026)	P	Wiki de memoria sobre trayectorias con procedencia para diálogo largo.	Mejoras en LoCoMo y MedMT.

Lectura conjunta. (i) Las comparaciones contra RAG no convergen: Wright (2026) y Ming et al. (2026b) favorecen al wiki en preguntas que cruzan fuentes; Zhang (2026a) y Huerta (2026b) muestran que una compilación ingenua pierde hechos y rinde menos que RAG; Cochran (2026b) muestra que el resultado depende de la línea base, de la granularidad de la medición y del juez. (ii) El argumento económico está en disputa: Wen y Ku (2026) reportan ahorro y Cochran (2026b) un sobrecosto por consulta. (iii) El mantenimiento es el punto débil: la organización se erosiona con el crecimiento (Zhou et al., 2026) y el mantenedor

degenera según la política de ingesta (Zhang, 2026a). (iv) Las muestras son pequeñas (10 a 59 preguntas en tres de las cinco comparaciones) y varios trabajos tienen autor único.

IV. Antecedentes: síntesis anticipada sin mantenimiento

Generación de artículos tipo wiki. STORM (Shao et al., 2024) genera artículos largos con preescritura guiada por perspectivas y los evalúa con FreshWiki; Co-STORM (Jiang et al., 2024) añade un humano y un mapa conceptual dinámico; WikiChat (Semnani et al., 2023) retiene solo los hechos fundamentados en el corpus. Los tres generan un artefacto una vez y no lo mantienen.

RAG estructurado. RAPTOR (Sarthi et al., 2024) precomputa un árbol de resúmenes; GraphRAG (Edge et al., 2024) extrae un grafo y resume comunidades; HippoRAG (Gutiérrez et al., 2024, 2025) y LightRAG (Guo et al., 2024) indexan sobre grafos. Comparten con el wiki la síntesis anticipada, pero en tripletas o resúmenes, no en prosa editable. Han et al. (2025) comparan RAG y GraphRAG bajo un protocolo único y concluyen que ninguno domina: la ventaja depende de la tarea.

Contexto largo. La generación aumentada por caché (Chan et al., 2024) precarga el corpus completo y elimina la recuperación; es el mecanismo de servicio que asume Huerta (2026b). Li et al. (2024) y Li et al. (2025) muestran que la elección entre contexto largo y RAG depende del modelo, la longitud y el tipo de pregunta.

V. Memoria de agentes

El wiki es un caso particular de memoria externa persistente. MemGPT (Packer et al., 2023) gestiona niveles de memoria con operaciones explícitas de lectura y escritura; los agentes generativos (Park et al., 2023) consolidan observaciones en reflexiones; CoALA (Sumers et al., 2023) ordena estas arquitecturas. A-MEM (Xu et al., 2025) mantiene notas enlazadas al estilo Zettelkasten que se reescriben al llegar memorias nuevas, y es el antecedente revisado por pares más cercano al patrón. Mem0 (Chhikara et al., 2025) y Zep (Rasmussen et al., 2025) son las referencias de uso industrial, la segunda con un grafo temporal.

Dynamic Cheatsheet (Suzgun et al., 2025) y ACE (Zhang et al., 2025) mantienen un contexto que evoluciona con el uso. ACE documenta dos fallas de la reescritura repetida: el *sesgo de brevedad* y el *colapso de contexto*, en el que los detalles se erosionan; las evita con actualizaciones incrementales estructuradas en lugar de reescrituras completas. Las revisiones de Hu et al. (2025) y Huang et al. (2026b) cubren el campo.

VI. El problema del mantenimiento

Propagación y deriva. Xiong et al. (2025) muestran que los agentes replican lo que recuperan de su memoria y que los errores almacenados se componen y degradan el desempeño posterior. Perez et al. (2024) muestran que en cadenas de reescritura entre modelos los sesgos pequeños se amplifican hacia estados atractores. Chen (2026) muestran que la compactación de contexto borra restricciones sin aviso. Lam et al. (2026) clasifican los riesgos de corrupción de memoria, entre ellos la deriva semántica por resumen iterativo. Treude y Baltes (2026) hallan referencias obsoletas en los archivos de configuración de agentes del 23 % de 356 repositorios.

Obsolescencia y contradicción. Los modelos manejan mal el conflicto entre lo almacenado y la evidencia nueva (Hase et al., 2024; Xu et al., 2024). STALE (Chao et al., 2026), MemConflict (Tao et al., 2026) y BeliefShift (Myakala et al., 2026) lo convierten en benchmark; el último define métricas de revisión de creencias y de resolución de contradicciones. MemOps (Hao et al., 2026) evalúa operaciones de memoria y no solo la respuesta final. Hu y Ramachandran (2026) encuentran que un dato obsoleto con apariencia de vigente engaña más a los modelos más capaces, y que exponer metadatos lo mitiga solo en ellos. MERIT (Mishra y Mishra, 2026) mide la utilidad de la memoria bajo contabilidad de costos y corrupción controla-

da: los almacenes que actualizan al escribir resisten mejor los hechos cambiantes que la recuperación por similitud.

Mecanismos de reparación. TOKI (Wang, 2026) y MemStrata (Yadav, 2026) resuelven contradicciones con registros bitemporales y reglas deterministas; NeuSymMS (Sultan et al., 2026) delega la detección a un componente simbólico. ChronoMem (Su et al., 2026) versiona la memoria y permite revertirla; Yu et al. (2026) reparan los estados derivados de una memoria defectuosa siguiendo sus dependencias. Todos operan sobre hechos atómicos o tripletas, no sobre prosa.

VII. Evaluación

Los benchmarks disponibles miden memoria conversacional (LoCoMo, Maharana et al., 2024; LongMemEval, Wu et al., 2024), generación única de artículos (FreshWiki, Shao et al., 2024) o síntesis de investigación (DeepScholar-Bench, Patel et al., 2025). Ninguno mide un corpus en prosa mantenido a lo largo de ingestas sucesivas.

Tres advertencias metodológicas salen de la literatura directa. El LLM como juez es inestable: en Cochran (2026b) el acuerdo entre jueces sobre fundamentación es casi nulo ($\rho = 0{,}04$) y la valoración global contradice la verificación cita por cita. El juez se sesga cuando el contenido es posterior a su corte de entrenamiento (Huerta, 2026a). Y el resultado depende de la fortaleza de la línea base RAG (Cochran, 2026b; Zhang, 2026a).

VIII. Síntesis y vacíos

Lo que la literatura sostiene.

1. El wiki compilado aventaja a RAG simple en preguntas que conectan varias fuentes; en hechos puntuales no hay diferencia (Cochran, 2026b; Ming et al., 2026b; Wright, 2026).
2. La compilación sin control pierde hechos y puede rendir menos que RAG (Huerta, 2026b; Zhang, 2026a).
3. La estructura del wiki se degrada al crecer con los modelos actuales (Zhou et al., 2026), y la reescritura repetida erosiona detalle (Zhang et al., 2025).
4. No hay arquitectura dominante: el resultado depende de la tarea, la línea base y el método de evaluación (Cochran, 2026b; Han et al., 2025).

Lo que falta. La Tabla II contrasta los vacíos con el trabajo más cercano a cada uno.

Posición del proyecto. Los seis vacíos están abiertos, pero ninguno está intacto: entre mayo y septiembre de 2026 aparecieron mediciones parciales de todos. El espacio no ocupado es la combinación: un wiki en prosa sobre literatura científica posterior al corte de entrenamiento, evaluado con preguntas de control fijas tras cada ingesta, con errores inyectados y procedencia por afirmación. Las advertencias sobre el juez y la línea base de la Sección VII condicionan ese diseño.

Referencias

Chan, B. J., Chen, C.-T., Cheng, J.-H., y Huang, H.-H. (2024). Don't Do RAG: When Cache-Augmented Generation is All You Need for Knowledge Tasks. arXiv:2412.15605. Publicado en WWW 2025 (short paper).

Chao, H., Bai, Y., Sheng, R., Li, T., y Sun, Y. (2026). STALE: Can LLM Agents Know When Their Memories Are No Longer Valid? arXiv:2605.06527. Preprint.

Chen, S. (2026). Governance Decay: How Context Compaction Silently Erases Safety Constraints in Long-Horizon LLM Agents. arXiv:2606.22528. Preprint.

Chhikara, P., Khant, D., Aryan, S., Singh, T., y Yadav, D. (2025). Mem0: Building Production-Ready AI Agents with Scalable Long-Term Memory. arXiv:2504.19413. Preprint.

Cochran, T. O. (2026a). Progressive Disclosure for LLM-Maintained Wiki Knowledge Bases: a Preregistered Ablation.

TABLA II
VACÍOS DE INVESTIGACIÓN Y TRABAJO MÁS CERCANO

Vacío	Trabajo más cercano	Qué no cubre
Calidad factual del wiki medida tras cada ingesta	Zhang (2026a): 8 lotes; Ran et al. (2026): 56 ingestas; Zhou et al. (2026): estudio de crecimiento	Muestra mínima; métricas estructurales y no factuales; memoria conversacional y no literatura
Supervivencia de un error a través de las ingestas	Zhang (2026c): retractación; Yu et al. (2026) y Mishra y Mishra (2026): corrupción controlada	Miden la reparación explícita en grafos o registros, no la persistencia espontánea en prosa
Efecto y frecuencia del *lint*	Huang et al. (2026a); Huerta (2026b); libro de errores de Ming et al. (2026b)	Proponen mecanismos; no varían la frecuencia ni aíslan su efecto sobre la calidad acumulada
Intervención humana	Zhang (2026c): umbral de revisión; Jiang et al. (2024)	No hay medición de cuánta revisión hace falta; Zhang (2026a) la deja como trabajo futuro
Compilación de fuentes de calidad desigual	Hu y Ramachandran (2026): confianza ante metadatos; Zhang (2026c): propagación de confianza	Nadie mide si compilar convierte una afirmación débil en prosa segura
Frontera de costo frente a RAG	Wen y Ku (2026); Cochran (2026b); Cochran (2026a)	Resultados contradictorios, sobre corpus pequeños y estáticos

arXiv:2607.04576. Preprint.

Cochran, T. O. (2026b). Single-Round Vector RAG vs an LLM-Compiled Wiki: A Preregistered Comparison on a Small Multi-Domain Research Corpus. arXiv:2605.18490. Preprint.

Dong, J., Luo, L., Zhang, S., Chen, G., Guo, T., Yu, Y., et al. (2026). WFM: Wiki Foundation Model for Complex Agentic Reasoning. arXiv:2609.18182. Preprint.

Edge, D., Trinh, H., Cheng, N., Bradley, J., Chao, A., Mody, A., et al. (2024). From Local to Global: A Graph RAG Approach to Query-Focused Summarization. arXiv:2404.16130. Preprint.

Garralda-Barrio, M. (2026). Knowledge-Centric Information Systems. arXiv:2607.02609. Preprint.

Guo, Z., Xia, L., Yu, Y., Ao, T., y Huang, C. (2024). LightRAG: Simple and Fast Retrieval-Augmented Generation. arXiv:2410.05779. Preprint.

Gutiérrez, B. J., Shu, Y., Gu, Y., Yasunaga, M., y Su, Y. (2024). HippoRAG: Neurobiologically Inspired Long-Term Memory for Large Language Models. arXiv:2405.14831. Publicado en NeurIPS 2024.

Gutiérrez, B. J., Shu, Y., Qi, W., Zhou, S., y Su, Y. (2025). From RAG to Memory: Non-Parametric Continual Learning for Large Language Models. arXiv:2502.14802. Publicado en ICML 2025.

Han, H., Ma, L., Wang, Y., Shomer, H., Lei, Y., Qi, Z., et al. (2025). RAG vs. GraphRAG: A Systematic Evaluation and Key Insights. arXiv:2502.11371. Preprint.

Hao, X., Zhang, Z., Lin, Z., Sun, Y., Guo, Z., Zhang, X., et al. (2026). MemOps: Benchmarking Lifecycle Memory Operations in Long-Horizon Conversations. arXiv:2607.12893. Preprint.

Hase, P., Hofweber, T., Zhou, X., Stengel-Eskin, E., y Bansal, M. (2024). Fundamental Problems With Model Editing: How Should Rational Belief Revision Work in LLMs? arXiv:2406.19354. Preprint.

Hu, J. y Ramachandran, S. (2026). The Memory Trust Gap: Capability-Dependent Failures in Persistent-Memory Agents. arXiv:2609.01852. Preprint.

Hu, Y., Liu, S., Yue, Y., Zhang, G., Liu, B., Zhu, F., et al. (2025). Memory in the Age of AI Agents. arXiv:2512.13564. Preprint.

Huang, H., Bai, J., Liu, S., Wei, Y., Jing, H., Tsang, H. T., et al. (2026a). DeepRefine: Agentic Knowledge Refinement via Reinforcement Learning. arXiv:2605.10488. Preprint.

Huang, W.-C., Zhang, W., Liang, Y., Bei, Y., Chen, Y., Feng, T., et al. (2026b). A Survey of Agent Memory in the

Second Half: Towards Self-Evolving and Long-Horizon Agents. arXiv:2602.06052. Publicado en TMLR (Survey Certification).

Huerta, J. M. (2026a). Streaming Knowledge Compilation: Proactive Materiality-Scored Pinning for Time-Evolving LLM Wikis. arXiv:2606.09877. Preprint.

Huerta, J. M. (2026b). WiCER: Wiki-memory Compile, Evaluate, Refine Iterative Knowledge Compilation for LLM Wiki Systems. arXiv:2605.07068. Preprint.

Jiang, Y., Shao, Y., Ma, D., Semnani, S. J., y Lam, M. S. (2024). Into the Unknown Unknowns: Engaged Human Learning through Participation in Language Model Agent Conversations. arXiv:2408.15232. Publicado en EMNLP 2024.

Karpathy, A. (2026). LLM Wiki. GitHub Gist, 4 de abril de 2026. Literatura gris.

Lam, C., Li, J., Zhang, L., y Zhao, K. (2026). Governing Evolving Memory in LLM Agents: Risks, Mechanisms, and the Stability and Safety Governed Memory (SSGM) Framework. arXiv:2603.11768. Preprint.

Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., et al. (2020). Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. arXiv:2005.11401. Publicado en NeurIPS 2020.

Li, K., Zhang, L., Jiang, Y., Xie, P., Huang, F., Wang, S., et al. (2025). LaRA: Benchmarking Retrieval-Augmented Generation and Long-Context LLMs – No Silver Bullet for LC or RAG Routing. arXiv:2502.09977. Preprint.

Li, Z., Li, C., Zhang, M., Mei, Q., y Bendersky, M. (2024). Retrieval Augmented Generation or Long-Context LLMs? A Comprehensive Study and Hybrid Approach. arXiv:2407.16833. Publicado en EMNLP 2024 Industry Track.

Maharana, A., Lee, D.-H., Tulyakov, S., Bansal, M., Barbieri, F., y Fang, Y. (2024). Evaluating Very Long-Term Conversational Memory of LLM Agents. arXiv:2402.17753. Publicado en ACL 2024.

Ming, H., Li, F., y Que, W. (2026a). WikiLoop: Jointly Learning to Build and Navigate Agent-Native Wikis with Downstream Feedback. arXiv:2607.26604. Preprint.

Ming, H., Li, F., Wu, X., y Que, W. (2026b). Retrieval as Reasoning: Self-Evolving Agent-Native Retrieval via LLM-Wiki. arXiv:2605.25480. Preprint.

Mishra, S. y Mishra, S. (2026). When Does Memory Help? A Cost-Aware Evaluation of Long-Term Memory in Tool-Using LLM Agents. arXiv:2609.05441. Preprint.

Miteski, S. (2026). Memory as Metabolism: A Design for Companion Knowledge Systems. arXiv:2604.12034. Preprint.

Moreira, P. S. y Sweet, C. R. (2026). Beyond Memory: A Templated Substrate for Heterogeneous Collaborative Knowledge Work with LLM Agents. arXiv:2607.24759. Preprint.

Myakala, P. K., Agrawal, M., y Manche, R. (2026). BeliefShift: Benchmarking Temporal Belief Consistency and Opinion Drift in LLM Agents. arXiv:2603.23848. Preprint.

Packer, C., Wooders, S., Lin, K., Fang, V., Patil, S. G., Stoica, I., et al. (2023). MemGPT: Towards LLMs as Operating Systems. arXiv:2310.08560. Preprint.

Park, J. S., O'Brien, J. C., Cai, C. J., Morris, M. R., Liang, P., y Bernstein, M. S. (2023). Generative Agents: Interactive Simulacra of Human Behavior. arXiv:2304.03442. Publicado en UIST 2023.

Patel, L., Arabzadeh, N., Gupta, H., Sundar, A., Stoica, I., Zaharia, M., et al. (2025). DeepScholar-Bench: A Live Benchmark and Automated Evaluation for Generative Research Synthesis. arXiv:2508.20033. Preprint.

Perez, J., Kovač, G., Léger, C., Colas, C., Molinaro, G., Derex, M., et al. (2024). When LLMs Play the Telephone Game: Cultural Attractors as Conceptual Tools to Evaluate LLMs in Multi-turn Settings. arXiv:2407.04503. Publicado en ICLR 2025.

Ran, S.-J., Zhang, K., Wu, X., Yang, L.-S., y Li, W.-J. (2026). LLMs Interpret, Embeddings Organize, Graphs Emerge: Agent-Driven Compilation of Scientific Knowledge. arXiv:2608.29612. Preprint.

Rasmussen, P., Paliychuk, P., Beauvais, T., Ryan, J., y Chalef, D. (2025). Zep: A Temporal Knowledge Graph Architecture for Agent Memory. arXiv:2501.13956. Preprint.

Roynard, M. (2026). The Missing Knowledge Layer in Cognitive Architectures for AI Agents. arXiv:2604.11364. Preprint.

Sarthi, P., Abdullah, S., Tuli, A., Khanna, S., Goldie, A., y Manning, C. D. (2024). RAPTOR: Recursive Abstractive Processing for Tree-Organized Retrieval. arXiv:2401.18059. Publicado en ICLR 2024.

Semnani, S. J., Yao, V. Z., Zhang, H. C., y Lam, M. S. (2023). WikiChat: Stopping the Hallucination of Large

Language Model Chatbots by Few-Shot Grounding on Wikipedia. arXiv:2305.14292. Publicado en Findings of EMNLP 2023.

Shao, Y., Jiang, Y., Kanell, T. A., Xu, P., Khattab, O., y Lam, M. S. (2024). Assisting in Writing Wikipedia-like Articles From Scratch with Large Language Models. arXiv:2402.14207. Publicado en NAACL 2024.

Su, Y., Xu, W., Zuo, C., y Bertino, E. (2026). ChronoMem: Version Control and Semantic Rollback for Large Language Model Agent Memory. arXiv:2607.27773. Preprint.

Sultan, M., Thuraisamy, S., y Rajaratnam, D. (2026). NeuSymMS: A Hybrid Neuro-Symbolic Memory System for Persistent, Self-Curating LLM Agents. arXiv:2605.17596. Preprint.

Sumers, T. R., Yao, S., Narasimhan, K., y Griffiths, T. L. (2023). Cognitive Architectures for Language Agents. arXiv:2309.02427. Publicado en TMLR.

Sun, J., Xue, Y., Li, M., Yao, Z., Li, J., Cui, Y., et al. (2026). TrajWiki: Source-Grounded Memory Trajectories for Long-Horizon Dialogue Agents. arXiv:2608.00967. Preprint.

Suzgun, M., Yuksekgonul, M., Bianchi, F., Jurafsky, D., y Zou, J. (2025). Dynamic Cheatsheet: Test-Time Learning with Adaptive Memory. arXiv:2504.07952. Preprint.

Tao, Z., Zhao, J., Liu, P., Xi, D., Chen, Y., Xu, W., et al. (2026). MemConflict: Evaluating Long-Term Memory Systems Under Memory Conflicts. arXiv:2605.20926. Preprint.

Treude, C. y Baltes, S. (2026). Context Rot in AI-Assisted Software Development: Repurposing Documentation Consistency for AI Configuration Artifacts. arXiv:2606.09090. Preprint.

Wang, Z. (2026). TOKI: A Bitemporal Operator Algebra for Contradiction Resolution in LLM-Agent Persistent Memory. arXiv:2606.06240. Preprint.

Wen, S. y Ku, B. (2026). Knowledge Compounding: An Empirical Economic Analysis of Self-Evolving Knowledge Wikis under the Agentic ROI Framework. arXiv:2604.11243. Preprint.

Wright, B. (2026). Potential for Enhanced Learning in Machine Learning Classes by Using Wiki LLM Indexing. arXiv:2609.25303. Preprint.

Wu, D., Wang, H., Yu, W., Zhang, Y., Chang, K.-W., y Yu, D. (2024). LongMemEval: Benchmarking Chat Assistants on Long-Term Interactive Memory. arXiv:2410.10813. Publicado en ICLR 2025.

Xiong, Z., Lin, Y., Xie, W., He, P., Liu, Z., Tang, J., et al. (2025). How Memory Management Impacts LLM Agents: An Empirical Study of Experience-Following Behavior. arXiv:2505.16067. Preprint.

Xu, R., Qi, Z., Guo, Z., Wang, C., Wang, H., Zhang, Y., et al. (2024). Knowledge Conflicts for LLMs: A Survey. arXiv:2403.08319. Publicado en EMNLP 2024.

Xu, W., Liang, Z., Mei, K., Gao, H., Tan, J., y Zhang, Y. (2025). A-MEM: Agentic Memory for LLM Agents. arXiv:2502.12110. Publicado en NeurIPS 2025.

Yadav, N. (2026). Temporal Validity in Retrieval Memory: Eliminating Stale-Fact Errors for AI Agents over Evolving Knowledge. arXiv:2606.26511. Preprint.

Yu, C., Wang, Y., Zhang, J., Duan, Y., Zheng, M., Wu, Z., et al. (2026). From Faulty Memories to Corrected Actions: Dependency-Guided Rollback Repair for Memory-Augmented Agents. arXiv:2608.10502. Preprint.

Zhang, B. (2026a). Does the wiki grow smarter? A pilot evaluation of LLM-maintained knowledge bases in an exception-dense decision-support task. SciErXiv, doi:10.20517/scierxiv202605.0291.v1. Preprint sin revisión por pares.

Zhang, B. (2026b). LLM Wiki as a Living Constraint Oracle for Safe Offline RL: Evidence from Type 1 Diabetes Glucose Management. *Transactions on Artificial Intelligence*, 2(1):178–189. doi:10.53941/tai.2026.100011.

Zhang, B. (2026c). Provenance-Native Audit Infrastructure for LLM-Maintained Wiki Knowledge Systems. *Artificial Intelligence and Emerging Technologies*, 3(3):10. doi:10.53941/aiet.2026.100010.

Zhang, Q., Hu, C., Upasani, S., Ma, B., Hong, F., Kamanuru, V., et al. (2025). Agentic Context Engineering: Evolving Contexts for Self-Improving Language Models. arXiv:2510.04618. Publicado en ICLR 2026.

Zhou, S., Yu, S., Wei, H., Wu, J., Ouyang, S., Jiao, Y., et al. (2026). Filesystem-Based Memory for LLM Agents: Organization, Evolution, and Sustainability. arXiv:2607.26637. Preprint.